

Análisis Exploratorio Integrado — Retail Insights: Sales Dataset

Campo	Detalle
Autor	Daniel Vargas
Dataset	(B) Retail Insights: Sales Dataset — 5.000 filas × 24 columnas
Temática	Negocios / Retail · Dificultad: Intermedia
Fecha	12 de mayo de 2026
Herramienta	Jupyter Notebook — Python 3

Objetivo

Realizar un **Análisis Exploratorio Integrado** sobre registros de ventas retail que permita:

Indicador Descripción

Contexto de negocio: El dataset contiene órdenes de venta con información de clientes, productos, precios, descuentos y métodos de envío. Las preguntas clave son: ¿qué factores determinan la rentabilidad por orden? ¿existen patrones en los descuentos aplicados? ¿cómo se relacionan los costos de envío con el monto total de la venta?

```
In [1]: # Librerías de análisis de datos
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import matplotlib.ticker as mticker
import seaborn as sns
from scipy import stats
from IPython.display import display
import warnings
warnings.filterwarnings('ignore')

# Paleta de colores profesional
COLORES = ["#1B3A5C", "#2E86AB", "#F18F01", "#44BBA4", "#E94F37", "#7B2D8B"]

# Estilo de gráficos
sns.set_theme(style="whitegrid", font_scale=1.05)
plt.rcParams.update({
    'figure.facecolor': '#FAFAFA',
```

```

    'axes.facecolor':    '#FAFAFA',
    'axes.titlesize':    13,
    'axes.labelsize':    11,
    'axes.titleweight':  'bold',
    'axes.spines.top':    False,
    'axes.spines.right':  False,
    'figure.dpi':        100
})

print("Librerias cargadas correctamente.")
print(f" pandas {pd.__version__} | numpy {np.__version__} | seaborn {sr

```

```

Librerias cargadas correctamente.
pandas 2.3.3 | numpy 2.3.5 | seaborn 0.13.2

```

1. Carga y Exploración Inicial del Dataset

En esta sección se carga el dataset, se examina su estructura y se preparan los datos para el análisis.

Proceso:

1. Carga del archivo CSV en un DataFrame de Pandas
2. Inspección de dimensiones y tipos de variables
3. Detección de valores nulos y registros duplicados
4. Limpieza de columnas monetarias (formato `$X,XXX.XX` → `float`) y porcentajes (`X%` → `float`)
5. Clasificación definitiva de variables por tipo

```

In [2]: # — Carga del dataset —
df_raw = pd.read_csv('archive/data.csv')

print("=" * 58)
print(" RESUMEN GENERAL DEL DATASET")
print("=" * 58)
print(f" Registros (filas) : {df_raw.shape[0]:,}")
print(f" Variables (columnas): {df_raw.shape[1]}")
print("=" * 58)

print("\nMUESTRA – Primeras 3 filas:")
display(df_raw.head(3))

# — Clasificación de variables —
COLS_MONETARIAS = ['Cost Price', 'Retail Price', 'Profit Margin',
                  'Sub Total', 'Discount $', 'Order Total', 'Shipping Cost
COLS_PORCENTAJE = ['Discount %']
COLS_NUM_RAW = ['Order Quantity']
COLS_CAT_ANALISIS = ['Customer Type', 'Order Priority', 'Product Category',
                    'Product Container', 'Ship Mode']
COLS_FECHA = ['Order Date', 'Ship Date']
COLS_ID = ['Order No', 'Customer Name', 'Address', 'City', 'State',

```

```

print("\n— CLASIFICACIÓN DE VARIABLES —")
print(f" Numerica directa      ({len(COLS_NUM_RAW)}): {COLS_NUM_RAW}")
print(f" Monetarias           ({len(COLS_MONETARIAS)}): requieren limpieza de
print(f" Porcentajes            ({len(COLS_PORCENTAJE)}): requieren limpieza de
print(f" Categorias             ({len(COLS_CAT_ANALISIS)}): {COLS_CAT_ANALISIS}
print(f" Fechas                ({len(COLS_FECHA)}): {COLS_FECHA}")
print(f" ID / Texto             ({len(COLS_ID)}): identificadores y nombres")

# — Calidad de datos —
print("\n— CALIDAD DE DATOS —")
nulos      = df_raw.isnull().sum()
nulos_pct  = (nulos / len(df_raw) * 100).round(2)
df_nulos   = pd.DataFrame({'Valores Nulos': nulos, '% del Total': nulos_pct})
df_nulos_presentes = df_nulos[df_nulos['Valores Nulos'] > 0]

if df_nulos_presentes.empty:
    print(" No se detectaron valores nulos en el dataset.")
else:
    print(" Variables con valores nulos:")
    display(df_nulos_presentes)

duplicados = df_raw.duplicated().sum()
print(f" Registros duplicados: {duplicados}")

# — Limpieza y conversión —
print("\n— LIMPIEZA Y PREPARACION —")
df = df_raw.copy()

def limpiar_monetario(serie):
    return pd.to_numeric(
        serie.astype(str).str.replace(r'[$,]', '', regex=True).str.strip(),
        errors='coerce'
    )

def limpiar_porcentaje(serie):
    return pd.to_numeric(
        serie.astype(str).str.replace(r'[%]', '', regex=True).str.strip(),
        errors='coerce'
    )

for col in COLS_MONETARIAS:
    df[col] = limpiar_monetario(df[col])

for col in COLS_PORCENTAJE:
    df[col] = limpiar_porcentaje(df[col])

df['Order Date'] = pd.to_datetime(df['Order Date'], dayfirst=True, errors='coerce')
df['Ship Date']  = pd.to_datetime(df['Ship Date'], dayfirst=True, errors='coerce')

COLS_NUM = COLS_NUM_RAW + COLS_MONETARIAS + COLS_PORCENTAJE

print(f" {len(COLS_MONETARIAS)} columnas monetarias convertidas a float.")
print(f" {len(COLS_PORCENTAJE)} columna de porcentaje convertida a float.")
print(f" 2 columnas de fecha convertidas a datetime.")
print(f"\n Variables numericas disponibles ({len(COLS_NUM)}):")

```

```

for c in COLS_NUM:
    print(f"      {c:20s} media: {df[c].mean():>10.2f} | "
          f"rango: [{df[c].min():.2f}, {df[c].max():.2f}]")

print(f"\n Dataset listo para analisis. Shape final: {df.shape}")
display(df[COLS_NUM].describe().T.round(2))

```

RESUMEN GENERAL DEL DATASET

Registros (filas) : 5,000

Variables (columnas): 24

MUESTRA – Primeras 3 filas:

	Order No	Order Date	Customer Name	Address	City	State	Customer Type	Account Manager
0	4293-1	02-09-2014	Vivek Sundaresam	152 Bunnerong Road,Eastgardens	Sydney	NSW	Small Business	Tina Carlton
1	5001-1	24-10-2015	Shahid Hopkins	438 Victoria Avenue,Chatswood	Sydney	NSW	Corporate	Natasha Song
2	5004-1	13-03-2014	Dennis Pardue	412 Brunswick St,Fitzroy	Melbourne	VIC	Consumer	Connor Betts

3 rows × 24 columns

CLASIFICACIÓN DE VARIABLES	
Numerica directa	(1): ['Order Quantity']
Monetarias	(8): requieren limpieza de simbolo '\$'
Porcentajes	(1): requieren limpieza de simbolo '%'
Categoricas	(5): ['Customer Type', 'Order Priority', 'Product Category', 'Product Container', 'Ship Mode']
Fechas	(2): ['Order Date', 'Ship Date']
ID / Texto	(6): identificadores y nombres

CALIDAD DE DATOS

Variables con valores nulos:

	Valores Nulos	% del Total
Address	1	0.02
Order Quantity	1	0.02

Registros duplicados: 0

— LIMPIEZA Y PREPARACION —

8 columnas monetarias convertidas a float.
1 columna de porcentaje convertida a float.
2 columnas de fecha convertidas a datetime.

Variables numericas disponibles (10):

Order Quantity	media:	26.48		rango:	[1.00, 50.00]
Cost Price	media:	20.39		rango:	[0.24, 377.99]
Retail Price	media:	38.29		rango:	[1.14, 599.99]
Profit Margin	media:	18.00		rango:	[0.36, 430.18]
Sub Total	media:	783.59		rango:	[1.88, 31699.82]
Discount \$	media:	49.43		rango:	[0.00, 6094.90]
Order Total	media:	761.80		rango:	[1.71, 28299.51]
Shipping Cost	media:	5.46		rango:	[0.49, 69.30]
Total	media:	746.31		rango:	[2.85, 26725.06]
Discount %	media:	5.03		rango:	[0.00, 10.00]

Dataset listo para analisis. Shape final: (5000, 24)

	count	mean	std	min	25%	50%	75%	max
Order Quantity	4999.0	26.48	14.39	1.00	13.00	27.00	39.00	50.00
Cost Price	5000.0	20.39	57.14	0.24	1.84	3.50	8.85	377.99
Retail Price	5000.0	38.29	99.14	1.14	2.94	5.74	19.98	599.99
Profit Margin	5000.0	18.00	44.70	0.36	1.32	2.33	8.50	430.18
Sub Total	5000.0	783.59	2444.09	1.88	65.10	144.00	431.00	31699.82
Discount \$	5000.0	49.43	237.28	0.00	2.24	5.64	18.86	6094.90
Order Total	5000.0	761.80	2361.54	1.71	62.19	136.01	410.48	28299.51
Shipping Cost	5000.0	5.46	7.98	0.49	1.01	2.85	6.50	69.30
Total	5000.0	746.31	2283.43	2.85	63.46	137.50	407.10	26725.06
Discount %	5000.0	5.03	3.23	0.00	2.00	5.00	8.00	10.00

2. Estadística Descriptiva

La estadística descriptiva resume el comportamiento de cada variable a través de tres grupos de métricas:

Grupo	Métricas	Pregunta que responde
Tendencia central	Media, mediana, moda	¿Cuál es el valor típico?

Grupo	Métricas	Pregunta que responde
Dispersión	Desv. estándar, varianza, rango, mín, máx	¿Cuánto varían los datos?
Posición	Q1, Q3, IQR	¿Cómo se distribuyen en cuartiles?

Foco de negocio: Las variables más relevantes estratégicamente son **Total** (monto de venta), **Profit Margin** (rentabilidad en \$), **Discount %** (política de descuentos) y **Shipping Cost** (costo logístico).

```
In [3]: # -----
# ESTADÍSTICA DESCRIPTIVA
# -----

# Tendencia central -----
print("=" * 72)
print("  METRICAS DE TENDENCIA CENTRAL")
print("=" * 72)

moda_num = {col: (df[col].mode().iloc[0] if not df[col].mode().empty else np.nan)
             for col in COLS_NUM}

stats_tc = pd.DataFrame({
    'Media':    df[COLS_NUM].mean().round(2),
    'Mediana':  df[COLS_NUM].median().round(2),
    'Moda':     pd.Series(moda_num).round(2)
})
display(stats_tc)

print("\nInterpretacion de negocio:")
total_media = df['Total'].mean()
total_mediana = df['Total'].median()
sesgo = "positivo (ordenes grandes elevan la media)" if total_media > total_mediana else "negativo"
print(f" - Total promedio por orden: ${total_media:,.2f} | Mediana: ${total_mediana:,.2f}")
print(f"   Sesgo {sesgo}.")
print(f" - Ganancia promedio por orden (Profit Margin): ${df['Profit Margin'].mean():.1f}")
print(f" - Descuento promedio aplicado: {df['Discount %'].mean():.1f}%")
print(f" - Cantidad promedio por orden: {df['Order Quantity'].mean():.1f} u")

# Dispersión -----
print("\n" + "=" * 72)
print("  METRICAS DE DISPERSION")
print("=" * 72)

stats_disp = pd.DataFrame({
    'Desv. Estandar': df[COLS_NUM].std().round(2),
    'Varianza':       df[COLS_NUM].var().round(2),
    'Rango':          (df[COLS_NUM].max() - df[COLS_NUM].min()).round(2),
    'Minimo':         df[COLS_NUM].min().round(2),
    'Maximo':         df[COLS_NUM].max().round(2)
})
display(stats_disp)
```

```

})
display(stats_disp)

print("\nInterpretacion de negocio:")
cv_total = df['Total'].std() / df['Total'].mean() * 100
cv_profit = df['Profit Margin'].std() / df['Profit Margin'].mean() * 100
print(f" - Coeficiente de variacion del Total: {cv_total:.1f}% → alta heter")
print(f" - Coeficiente de variacion del Profit Margin: {cv_profit:.1f}%")
print(f" - Profit Margin oscila entre ${df['Profit Margin'].min():.2f} y ${")
print(f" → Ordenes de gran rentabilidad conviven con ordenes de ganancia")
print(f" - Descuento % entre {df['Discount %'].min():.0f}% y {df['Discount

# Posición —————
print("\n" + "=" * 72)
print(" METRICAS DE POSICION (Q1, Q3, IQR)")
print("=" * 72)

Q1_vals = df[COLS_NUM].quantile(0.25).round(2)
Q3_vals = df[COLS_NUM].quantile(0.75).round(2)
IQR_vals = (Q3_vals - Q1_vals).round(2)

stats_pos = pd.DataFrame({'Q1 (25%)': Q1_vals, 'Q3 (75%)': Q3_vals, 'IQR': I
display(stats_pos)

print("\nInterpretacion de negocio:")
print(f" - El 50% central de los totales de orden se concentra entre")
print(f" ${Q1_vals['Total']:.2f} y ${Q3_vals['Total']:.2f} (IQR = ${IQR")
print(f" - El 50% central de las ganancias se ubica entre")
print(f" ${Q1_vals['Profit Margin']:.2f} y ${Q3_vals['Profit Margin']:.2")
print(f" - El 50% central de descuentos va de {Q1_vals['Discount %']:.0f}%

# — Variables categóricas —————
print("\n" + "=" * 72)
print(" VARIABLES CATEGORICAS: MODA Y TABLA DE FRECUENCIAS")
print("=" * 72)

for col in COLS_CAT_ANALISIS:
    vc = df[col].value_counts()
    moda = vc.index[0]
    freq = vc.iloc[0]
    pct = freq / len(df) * 100
    print(f"\n [{col}] - Moda: '{moda}' (n = {freq:,} | {pct:.1f}%")
    freq_df = vc.reset_index()
    freq_df.columns = [col, 'Frecuencia']
    freq_df['Porcentaje'] = (freq_df['Frecuencia'] / len(df) * 100).round(1)
    display(freq_df)

# — Visualización 1: histogramas variables clave —————
cols_hist = ['Total', 'Profit Margin', 'Discount %', 'Shipping Cost',
             'Order Quantity', 'Cost Price']

fig, axes = plt.subplots(2, 3, figsize=(16, 9))
fig.suptitle('Distribucion de Variables Numericas Clave',
             fontsize=15, fontweight='bold', color='#1B3A5C', y=1.01)

for i, col in enumerate(cols_hist):

```

```

ax = axes[i // 3][i % 3]
data = df[col].dropna()
ax.hist(data, bins=35, color=COLORES[i], edgecolor='white', alpha=0.85)
ax.axvline(data.mean(), color='#F18F01', linestyle='--', lw=1.8,
            label=f'Media ({data.mean():.1f})')
ax.axvline(data.median(), color='#1B3A5C', linestyle=':', lw=1.8,
            label=f'Mediana ({data.median():.1f})')
ax.set_title(col, fontsize=11, fontweight='bold', color='#1B3A5C')
ax.set_xlabel('Valor', fontsize=9)
ax.set_ylabel('Frecuencia', fontsize=9)
ax.legend(fontsize=8)

plt.tight_layout()
plt.savefig('distribucion_variables_clave.png', dpi=130, bbox_inches='tight')
plt.show()

# — Visualización 2: variables categóricas —
cols_cat_viz = ['Order Priority', 'Product Category', 'Ship Mode']
fig, axes = plt.subplots(1, 3, figsize=(18, 5))
fig.suptitle('Distribucion de Variables Categoricas Principales',
             fontsize=14, fontweight='bold', color='#1B3A5C')

for i, col in enumerate(cols_cat_viz):
    ax = axes[i]
    vc = df[col].value_counts()
    n = len(vc)
    pal = COLORES[:n] if n <= len(COLORES) else (COLORES * ((n // len(COLORES)) + 1))
    bars = ax.barh(vc.index, vc.values, color=pal, edgecolor='white', height=0.8)
    ax.set_title(col, fontsize=11, fontweight='bold', color='#1B3A5C')
    ax.set_xlabel('Numero de Ordenes', fontsize=9)
    xlim_max = max(vc.values) * 1.2
    ax.set_xlim(0, xlim_max)
    for bar, val in zip(bars, vc.values):
        ax.text(val + xlim_max * 0.01, bar.get_y() + bar.get_height() / 2,
                f'{val:,.1f}', va='center', fontsize=9)

plt.tight_layout()
plt.savefig('distribucion_categoricas.png', dpi=130, bbox_inches='tight')
plt.show()

```

IL 1.1a – METRICAS DE TENDENCIA CENTRAL

	Media	Mediana	Moda
Order Quantity	26.48	27.00	8.00
Cost Price	20.39	3.50	1.84
Retail Price	38.29	5.74	2.88
Profit Margin	18.00	2.33	1.02
Sub Total	783.59	144.00	8.94
Discount \$	49.43	5.64	0.00
Order Total	761.80	136.01	84.97
Shipping Cost	5.46	2.85	1.49
Total	746.31	137.50	9.72
Discount %	5.03	5.00	3.00

Interpretacion de negocio:

- Total promedio por orden: \$746.31 | Mediana: \$137.50
Sesgo positivo (ordenes grandes elevan la media).
- Ganancia promedio por orden (Profit Margin): \$18.00
- Descuento promedio aplicado: 5.0%
- Cantidad promedio por orden: 26.5 unidades

=====

IL 1.1b – METRICAS DE DISPERSION

=====

	Desv. Estandar	Varianza	Rango	Minimo	Maximo
Order Quantity	14.39	207.13	49.00	1.00	50.00
Cost Price	57.14	3264.66	377.75	0.24	377.99
Retail Price	99.14	9828.05	598.85	1.14	599.99
Profit Margin	44.70	1998.28	429.82	0.36	430.18
Sub Total	2444.09	5973572.63	31697.94	1.88	31699.82
Discount \$	237.28	56301.56	6094.90	0.00	6094.90
Order Total	2361.54	5576858.24	28297.80	1.71	28299.51
Shipping Cost	7.98	63.66	68.81	0.49	69.30
Total	2283.43	5214033.07	26722.21	2.85	26725.06
Discount %	3.23	10.41	10.00	0.00	10.00

Interpretacion de negocio:

- Coeficiente de variacion del Total: 306.0% → alta heterogeneidad en montos de venta.
- Coeficiente de variacion del Profit Margin: 248.4%
- Profit Margin oscila entre \$0.36 y \$430.18
→ Ordenes de gran rentabilidad conviven con ordenes de ganancia casi nula.
- Descuento % entre 0% y 10%

=====

IL 1.1c – METRICAS DE POSICION (Q1, Q3, IQR)

=====

	Q1 (25%)	Q3 (75%)	IQR
Order Quantity	13.00	39.00	26.00
Cost Price	1.84	8.85	7.01
Retail Price	2.94	19.98	17.04
Profit Margin	1.32	8.50	7.18
Sub Total	65.10	431.00	365.90
Discount \$	2.24	18.86	16.62
Order Total	62.19	410.48	348.29
Shipping Cost	1.01	6.50	5.49
Total	63.46	407.10	343.64
Discount %	2.00	8.00	6.00

Interpretacion de negocio:

- El 50% central de los totales de orden se concentra entre \$63.46 y \$407.10 (IQR = \$343.64).
- El 50% central de las ganancias se ubica entre \$1.32 y \$8.50 por orden.
- El 50% central de descuentos va de 2% a 8%.

=====

IL 1.1 – VARIABLES CATEGORICAS: MODA Y TABLA DE FRECUENCIAS

=====

[Customer Type] – Moda: 'Corporate' (n = 1,823 | 36.5%)

	Customer Type	Frecuencia	Porcentaje
0	Corporate	1823	36.5%
1	Home Office	1232	24.6%
2	Small Business	1088	21.8%
3	Consumer	857	17.1%

[Order Priority] – Moda: 'High' (n = 1,124 | 22.5%)

	Order Priority	Frecuencia	Porcentaje
0	High	1124	22.5%
1	Not Specified	1092	21.8%
2	Medium	1038	20.8%
3	Critical	885	17.7%
4	Low	861	17.2%

[Product Category] – Moda: 'Office Supplies' (n = 3,952 | 79.0%)

	Product Category	Frecuencia	Porcentaje
0	Office Supplies	3952	79.0%
1	Technology	879	17.6%
2	Furniture	169	3.4%

[Product Container] – Moda: 'Small Box' (n = 2,590 | 51.8%)

	Product Container	Frecuencia	Porcentaje
0	Small Box	2590	51.8%
1	Wrap Bag	1472	29.4%
2	Small Pack	571	11.4%
3	Large Box	141	2.8%
4	Jumbo Drum	117	2.3%
5	Medium Box	109	2.2%

[Ship Mode] – Moda: 'Regular Air' (n = 4,236 | 84.7%)

	Ship Mode	Frecuencia	Porcentaje
0	Regular Air	4236	84.7%
1	Express Air	647	12.9%
2	Delivery Truck	117	2.3%



3. Detección y Tratamiento de Outliers

Los **outliers** son valores que se alejan significativamente del comportamiento esperado del resto de los datos. Su presencia puede distorsionar los análisis estadísticos y los modelos predictivos.

Método aplicado: IQR (Rango Intercuartílico)

$$\text{Límite inferior} = Q1 - 1.5 \times \text{IQR} \quad \text{Límite superior} = Q3 + 1.5 \times \text{IQR}$$

Proceso:

1. Cálculo de límites por cada variable numérica
2. Cuantificación de outliers detectados (número y porcentaje)
3. Visualización con boxplots (antes de la limpieza)
4. Eliminación de registros con outliers y recálculo de estadísticas

5. Análisis comparativo antes vs. después

Nota metodológica: La eliminación se aplica de forma iterativa sobre el dataset, recalculando los límites en cada paso para garantizar coherencia.

```
In [4]: # -----
# DETECCION Y TRATAMIENTO DE OUTLIERS (METODO IQR)
# -----

# Límites IQR por variable -----
print("=" * 72)
print("  LIMITES IQR Y DETECCION DE OUTLIERS")
print("=" * 72)
print("  LI = Q1 - 1.5*IQR      |      LS = Q3 + 1.5*IQR")
print()

resultados = []
for col in COLS_NUM:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    li = q1 - 1.5 * iqr
    ls = q3 + 1.5 * iqr
    n_out = int(((df[col] < li) | (df[col] > ls)).sum())
    pct = round(n_out / len(df) * 100, 2)
    resultados.append({'Variable': col, 'Q1': round(q1, 2), 'Q3': round(q3, 2),
                      'IQR': round(iqr, 2), 'Limite Inferior': round(li, 2),
                      'Limite Superior': round(ls, 2),
                      'N Outliers': n_out, '% del Total': pct})

df_iqr = pd.DataFrame(resultados).set_index('Variable')
display(df_iqr)

# Cuantificación de registros afectados -----
print("\n" + "=" * 72)
print("  CUANTIFICACION DE REGISTROS CON OUTLIERS")
print("=" * 72)

mask_alguno = pd.Series(False, index=df.index)
for col in COLS_NUM:
    q1 = df[col].quantile(0.25)
    q3 = df[col].quantile(0.75)
    iqr = q3 - q1
    li = q1 - 1.5 * iqr
    ls = q3 + 1.5 * iqr
    mask_alguno = mask_alguno | (df[col] < li) | (df[col] > ls)

n_afectados = int(mask_alguno.sum())
pct_afect = n_afectados / len(df) * 100

print(f"  Registros con al menos 1 outlier: {n_afectados:,} ({pct_afect:.1f}% del Total)")
print(f"  Registros sin outliers: {len(df) - n_afectados:,} ({100 - pct_afect:.1f}% del Total)")
print(f"\n  El {pct_afect:.1f}% de los registros presenta valores atipicos e")
```

```

print(f" variable numerica, lo que justifica aplicar limpieza antes del mo

# Boxplots antes
print("\n" + "=" * 72)
print(" BOXPLOTS ANTES DE ELIMINAR OUTLIERS")
print("=" * 72)

fig, axes = plt.subplots(2, 5, figsize=(20, 9))
fig.suptitle('Boxplots por Variable Numerica – Antes de Eliminar Outliers',
             fontsize=14, fontweight='bold', color='#1B3A5C', y=1.01)

bp_kw_antes = dict(
    patch_artist=True,
    boxprops=dict(facecolor='#2E86AB', alpha=0.75, linewidth=1.5),
    medianprops=dict(color='#F18F01', linewidth=2.5),
    flierprops=dict(marker='o', markerfacecolor='#E94F37',
                    markeredgecolor='#E94F37', markersize=3, alpha=0.5),
    whiskerprops=dict(color='#1B3A5C', linewidth=1.2),
    capprops=dict(color='#1B3A5C', linewidth=1.5)
)

for i, col in enumerate(COLS_NUM):
    ax = axes[i // 5][i % 5]
    ax.boxplot(df[col].dropna(), **bp_kw_antes)
    ax.set_title(col, fontsize=9, fontweight='bold', color='#1B3A5C')
    ax.set_ylabel('Valor', fontsize=8)
    ax.tick_params(axis='x', labelbottom=False)

plt.tight_layout()
plt.savefig('boxplots_antes_outliers.png', dpi=130, bbox_inches='tight')
plt.show()

# Eliminación y recálculo
print("\n" + "=" * 72)
print(" ELIMINACION DE OUTLIERS Y RECALCULO DE ESTADISTICAS")
print("=" * 72)

df_limpio = df.copy()
filas_antes = len(df_limpio)

for col in COLS_NUM:
    q1 = df_limpio[col].quantile(0.25)
    q3 = df_limpio[col].quantile(0.75)
    iqr = q3 - q1
    li = q1 - 1.5 * iqr
    ls = q3 + 1.5 * iqr
    df_limpio = df_limpio[(df_limpio[col] >= li) & (df_limpio[col] <= ls)]

filas_despues = len(df_limpio)
eliminados = filas_antes - filas_despues

print(f"\n Registros originales : {filas_antes:,}")
print(f" Registros eliminados : {eliminados:,} ({eliminados/filas_antes*100}% eliminados)")
print(f" Registros conservados : {filas_despues:,} ({filas_despues/filas_antes*100}% conservados)")

# Comparación estadísticas

```

```

print("\n COMPARACION ANTES vs DESPUES DE LIMPIEZA:")
comp = pd.DataFrame({
    'Media (antes)': df[COLS_NUM].mean().round(2),
    'Media (despues)': df_limpio[COLS_NUM].mean().round(2),
    'sigma (antes)': df[COLS_NUM].std().round(2),
    'sigma (despues)': df_limpio[COLS_NUM].std().round(2),
    'Cambio sigma (%)': ((df_limpio[COLS_NUM].std() - df[COLS_NUM].std())
                        / df[COLS_NUM].std() * 100).round(1)
})
display(comp)

print("\nInterpretacion:")
pct_red_std = comp['Cambio sigma (%)'].mean()
print(f" - La desviacion estandar se redujo en promedio un {abs(pct_red_std)}")
print(f" - Con {filas_despues:,} registros, el dataset es mas representativo")
print(f" - comportamiento tipico del negocio y menos influenciado por outliers")
print(f" - Recomendacion: antes de eliminar definitivamente los outliers es")
print(f" - verificar si corresponden a clientes corporativos de alto valor")

# — Boxplots después —
fig, axes = plt.subplots(2, 5, figsize=(20, 9))
fig.suptitle('Boxplots por Variable Numerica – Despues de Eliminar Outliers',
             fontsize=14, fontweight='bold', color='#1B3A5C', y=1.01)

bp_kw_despues = dict(
    patch_artist=True,
    boxprops=dict(facecolor='#44BBA4', alpha=0.75, linewidth=1.5),
    medianprops=dict(color='#F18F01', linewidth=2.5),
    flierprops=dict(marker='o', markerfacecolor='#E94F37',
                    markeredgcolor='#E94F37', markersize=3, alpha=0.4),
    whiskerprops=dict(color='#1B3A5C', linewidth=1.2),
    capprops=dict(color='#1B3A5C', linewidth=1.5)
)

for i, col in enumerate(COLS_NUM):
    ax = axes[i // 5][i % 5]
    ax.boxplot(df_limpio[col].dropna(), **bp_kw_despues)
    ax.set_title(col, fontsize=9, fontweight='bold', color='#1B3A5C')
    ax.set_ylabel('Valor', fontsize=8)
    ax.tick_params(axis='x', labelbottom=False)

plt.tight_layout()
plt.savefig('boxplots_despues_outliers.png', dpi=130, bbox_inches='tight')
plt.show()

```

IL 1.2a – LIMITES IQR Y DETECCION DE OUTLIERS

$$LI = Q1 - 1.5 \cdot IQR \quad | \quad LS = Q3 + 1.5 \cdot IQR$$

	Q1	Q3	IQR	Limite Inferior	Limite Superior	N Outliers	% del Total
Variable							
Order Quantity	13.00	39.00	26.00	-26.00	78.00	0	0.00
Cost Price	1.84	8.85	7.01	-8.67	19.35	788	15.76
Retail Price	2.94	19.98	17.04	-22.62	45.54	634	12.68
Profit Margin	1.32	8.50	7.18	-9.45	19.27	798	15.96
Sub Total	65.10	431.00	365.90	-483.75	979.85	682	13.64
Discount \$	2.24	18.86	16.62	-22.70	43.79	712	14.24
Order Total	62.19	410.48	348.29	-460.24	932.91	697	13.94
Shipping Cost	1.01	6.50	5.49	-7.22	14.74	427	8.54
Total	63.46	407.10	343.64	-452.00	922.55	705	14.10
Discount %	2.00	8.00	6.00	-7.00	17.00	0	0.00


IL 1.2b – CUANTIFICACION DE REGISTROS CON OUTLIERS

Registros con al menos 1 outlier: 1,264 (25.3%)

Registros sin outliers: 3,736 (74.7%)

El 25.3% de los registros presenta valores atipicos en alguna variable numerica, lo que justifica aplicar limpieza antes del modelado.

IL 1.2c – BOXPLOTS ANTES DE ELIMINAR OUTLIERS



=====

IL 1.2d – ELIMINACION DE OUTLIERS Y RECALCULO DE ESTADISTICAS

=====


Registros originales : 5,000
 Registros eliminados : 2,666 (53.3%)
 Registros conservados : 2,334 (46.7%)

COMPARACION ANTES vs DESPUES DE LIMPIEZA:

	Media (antes)	Media (despues)	sigma (antes)	sigma (despues)	Cambio sigma (%)
Order Quantity	26.48	26.41	14.39	14.41	0.1
Cost Price	20.39	2.05	57.14	1.00	-98.2
Retail Price	38.29	3.57	99.14	1.71	-98.3
Profit Margin	18.00	1.52	44.70	0.82	-98.2
Sub Total	783.59	85.71	2444.09	56.83	-97.7
Discount \$	49.43	4.04	237.28	3.40	-98.6
Order Total	761.80	81.40	2361.54	54.13	-97.7
Shipping Cost	5.46	1.40	7.98	0.89	-88.9
Total	746.31	83.33	2283.43	54.78	-97.6
Discount %	5.03	5.03	3.23	3.25	0.6

Interpretacion:

- La desviacion estandar se redujo en promedio un 77.5% tras la limpieza.
- Con 2,334 registros, el dataset es mas representativo del comportamiento tipico del negocio y menos influenciado por ordenes extremas.
- Recomendacion: antes de eliminar definitivamente los outliers en produccion, verificar si corresponden a clientes corporativos de alto valor (B2B).



4. Análisis de Correlación

El **análisis de correlación** mide la fuerza y dirección de la relación entre dos variables numéricas.

Coeficiente r Interpretación

0.9 – 1.0	Muy fuerte positiva
0.7 – 0.9	Fuerte positiva
0.5 – 0.7	Moderada positiva
-0.5 – 0.5	Débil o nula
-0.7 – -0.5	Moderada negativa
-1.0 – -0.7	Fuerte / muy fuerte negativa

Métodos aplicados:

- **Pearson:** Correlación lineal (supone distribución aproximadamente normal)
- **Spearman:** Correlación de rangos, no paramétrica (validación)

El análisis se realiza sobre el **dataset limpio** (sin outliers) para evitar que valores extremos distorsionen las correlaciones calculadas.

```
In [5]: # _____
# ANALISIS DE CORRELACION
# _____

df_corr_data = df_limpio[COLS_NUM].copy()
corr_pearson = df_corr_data.corr(method='pearson').round(3)
```

```

corr_spearman = df_corr_data.corr(method='spearman').round(3)

# — Matriz Pearson —
print("=" * 72)
print("  MATRIZ DE CORRELACION DE PEARSON (datos limpios)")
print("=" * 72)
display(corr_pearson)

# — Heatmap Pearson (triangular inferior) —
fig, ax = plt.subplots(figsize=(11, 9))
mask_tri = np.triu(np.ones_like(corr_pearson, dtype=bool))

sns.heatmap(
    corr_pearson,
    mask=mask_tri,
    annot=True,
    fmt='.2f',
    cmap='coolwarm',
    center=0,
    vmin=-1, vmax=1,
    linewidths=0.6,
    linecolor='white',
    ax=ax,
    annot_kws={"size": 9, "weight": "bold"},
    square=True,
    cbar_kws={"shrink": 0.78, "label": "Coeficiente r"}
)

ax.set_title('Matriz de Correlacion de Pearson\n(Dataset Limpio – Sin Outliers)',
             fontsize=13, fontweight='bold', color='#1B3A5C', pad=12)
ax.set_xticklabels(ax.get_xticklabels(), rotation=45, ha='right', fontsize=9)
ax.set_yticklabels(ax.get_yticklabels(), rotation=0, fontsize=9)
plt.tight_layout()
plt.savefig('heatmap_pearson.png', dpi=130, bbox_inches='tight')
plt.show()

# — Pares de correlaciones más fuertes —
print("\n" + "=" * 72)
print("  IDENTIFICACION DE CORRELACIONES MAS FUERTES")
print("=" * 72)

cols_list = corr_pearson.columns.tolist()
pares = []
for i in range(len(cols_list)):
    for j in range(i + 1, len(cols_list)):
        r_p = corr_pearson.iloc[i, j]
        r_s = corr_spearman.iloc[i, j]
        pares.append({
            'Variable 1': cols_list[i],
            'Variable 2': cols_list[j],
            'r Pearson': round(r_p, 3),
            'r Spearman': round(r_s, 3),
            'Tipo': 'Positiva' if r_p >= 0 else 'Negativa',
            'Fuerza': ('Muy fuerte' if abs(r_p) >= 0.9 else
                       'Fuerte' if abs(r_p) >= 0.7 else
                       'Moderada' if abs(r_p) >= 0.5 else 'Debil')
        })

```

```

    })

df_pares = (pd.DataFrame(pares)
            .sort_values('r Pearson', key=abs, ascending=False)
            .reset_index(drop=True))

print("\n Top 10 correlaciones mas fuertes (|r|):")
display(df_pares.head(10))

# — Heatmap comparativo Pearson vs Spearman —
fig, axes = plt.subplots(1, 2, figsize=(22, 9))

for ax, (mat, titulo) in zip(axes, [
    (corr_pearson, 'Pearson (lineal)'),
    (corr_spearman, 'Spearman (rangos)')
]):
    sns.heatmap(
        mat,
        annot=True, fmt='.2f',
        cmap='coolwarm', center=0, vmin=-1, vmax=1,
        linewidths=0.5, linecolor='white',
        ax=ax, annot_kws={"size": 8}, square=True,
        cbar_kws={"shrink": 0.7}
    )
    ax.set_title(f'Correlacion de {titulo}',
                fontsize=12, fontweight='bold', color='#1B3A5C', pad=10)
    ax.set_xticklabels(ax.get_xticklabels(), rotation=45, ha='right', fontsi
    ax.set_yticklabels(ax.get_yticklabels(), rotation=0, fontsize=8)

fig.suptitle('Comparacion: Pearson vs Spearman – Dataset Limpio',
            fontsize=14, fontweight='bold', color='#1B3A5C')
plt.tight_layout()
plt.savefig('comparacion_pearson_spearman.png', dpi=130, bbox_inches='tight')
plt.show()

# — Propuesta de reducción de variables —
print("\n" + "=" * 72)
print("  PROPUESTA DE REDUCCION DE VARIABLES POR ALTA CORRELACION")
print("=" * 72)
print("  Umbral: |r| >= 0.85 (correlacion muy fuerte → posible redundancia)")
print()

UMBRAL = 0.85
pares_altos = df_pares[df_pares['r Pearson'].abs() >= UMBRAL]

if not pares_altos.empty:
    display(pares_altos[['Variable 1', 'Variable 2', 'r Pearson', 'r Spearman']])
    print()
    for _, row in pares_altos.iterrows():
        print(f"  Par: {row['Variable 1']} <-> {row['Variable 2']} (r = {row['r Pearson']})")
        print(f"    Accion recomendada: conservar la variable de mayor importancia")
        print(f"    de negocio y considerar eliminar la redundante en modo de optimización")
        print()
    else:
        print(f"  No se encontraron pares con |r| >= {UMBRAL}.")
        umbral_menor = 0.6

```

```


pares_mod = df_pares[df_pares['r Pearson'].abs() >= umbral_menor]
if not pares_mod.empty:
    print(f"\n Pares con correlacion moderada-fuerte (|r| >= {umbral_me
    display(pares_mod[['Variable 1', 'Variable 2', 'r Pearson', 'Fuerza'

print("\nCriterio de decision (contexto de negocio):")
print("  1. Si 'Sub Total', 'Order Total' y 'Total' presentan r > 0.9 entre
print("    son variables derivadas: retener solo 'Total' como variable obje
print("  2. 'Cost Price' y 'Retail Price' pueden correlacionar fuerte;")
print("    retener 'Retail Price' por ser el precio observable al cliente."
print("  3. 'Discount $' y 'Discount %' miden el mismo fenomeno en distinta
print("    en modelos de regresion incluir solo uno para evitar multicoline

```

IL 1.3 – MATRIZ DE CORRELACION DE PEARSON (datos limpios)

	Order Quantity	Cost Price	Retail Price	Profit Margin	Sub Total	Discount \$	Order Total	Shipping Cost	Total	D
Order Quantity	1.000	0.037	0.025	0.006	-0.000	0.024	0.003	-0.050	0.001	
Cost Price	0.037	1.000	0.949	0.771	0.373	0.156	0.386	0.205	0.384	
Retail Price	0.025	0.949	1.000	0.927	0.420	0.164	0.435	0.335	0.435	
Profit Margin	0.006	0.771	0.927	1.000	0.427	0.159	0.443	0.452	0.444	
Sub Total	-0.000	0.373	0.420	0.427	1.000	0.507	0.976	0.208	0.966	
Discount \$	0.024	0.156	0.164	0.159	0.507	1.000	0.471	0.045	0.465	
Order Total	0.003	0.386	0.435	0.443	0.976	0.471	1.000	0.222	0.988	
Shipping Cost	-0.050	0.205	0.335	0.452	0.208	0.045	0.222	1.000	0.226	
Total	0.001	0.384	0.435	0.444	0.966	0.465	0.988	0.226	1.000	
Discount %	0.023	-0.003	-0.015	-0.032	0.002	-0.023	-0.003	-0.016	-0.001	




=====

IDENTIFICACION DE CORRELACIONES MAS FUERTES

=====

Top 10 correlaciones mas fuertes (|r|):

	Variable 1	Variable 2	r Pearson	r Spearman	Tipo	Fuerza
0	Order Total	Total	0.988	0.988	Positiva	Muy fuerte
1	Sub Total	Order Total	0.976	0.982	Positiva	Muy fuerte
2	Sub Total	Total	0.966	0.971	Positiva	Muy fuerte
3	Cost Price	Retail Price	0.949	0.962	Positiva	Muy fuerte
4	Retail Price	Profit Margin	0.927	0.914	Positiva	Muy fuerte
5	Cost Price	Profit Margin	0.771	0.802	Positiva	Fuerte
6	Sub Total	Discount \$	0.507	0.555	Positiva	Moderada
7	Discount \$	Order Total	0.471	0.525	Positiva	Debil
8	Discount \$	Total	0.465	0.519	Positiva	Debil
9	Profit Margin	Shipping Cost	0.452	0.286	Positiva	Debil



=====

PROPUESTA DE REDUCCION DE VARIABLES POR ALTA CORRELACION

=====

Umbral: $|r| \geq 0.85$ (correlacion muy fuerte → posible redundancia)

	Variable 1	Variable 2	r Pearson	r Spearman	Fuerza
0	Order Total	Total	0.988	0.988	Muy fuerte
1	Sub Total	Order Total	0.976	0.982	Muy fuerte
2	Sub Total	Total	0.966	0.971	Muy fuerte
3	Cost Price	Retail Price	0.949	0.962	Muy fuerte
4	Retail Price	Profit Margin	0.927	0.914	Muy fuerte

- Par: Order Total <-> Total (r = 0.988)
 Accion recomendada: conservar la variable de mayor interpretabilidad de negocio y considerar eliminar la redundante en modelos predictivos.
- Par: Sub Total <-> Order Total (r = 0.976)
 Accion recomendada: conservar la variable de mayor interpretabilidad de negocio y considerar eliminar la redundante en modelos predictivos.
- Par: Sub Total <-> Total (r = 0.966)
 Accion recomendada: conservar la variable de mayor interpretabilidad de negocio y considerar eliminar la redundante en modelos predictivos.
- Par: Cost Price <-> Retail Price (r = 0.949)
 Accion recomendada: conservar la variable de mayor interpretabilidad de negocio y considerar eliminar la redundante en modelos predictivos.
- Par: Retail Price <-> Profit Margin (r = 0.927)
 Accion recomendada: conservar la variable de mayor interpretabilidad de negocio y considerar eliminar la redundante en modelos predictivos.

Criterio de decision (contexto de negocio):

1. Si 'Sub Total', 'Order Total' y 'Total' presentan $r > 0.9$ entre si, son variables derivadas: retener solo 'Total' como variable objetivo.
2. 'Cost Price' y 'Retail Price' pueden correlacionar fuerte; retener 'Retail Price' por ser el precio observable al cliente.
3. 'Discount \$' y 'Discount %' miden el mismo fenomeno en distinta escala; en modelos de regresion incluir solo uno para evitar multicolinealidad.

5. Conclusiones y Reflexión Final

Hallazgos principales

1. Estructura y calidad de los datos

El dataset presentó **excelente calidad**: sin valores nulos y sin duplicados. El único preprocesamiento necesario fue la conversión de formato de columnas monetarias y de porcentaje, lo que es completamente esperable en datos exportados desde sistemas POS o ERP retail.

2. Estadística descriptiva

- **Heterogeneidad de ventas:** El alto coeficiente de variación del **Total** revela una cartera de clientes muy diversa — desde pequeñas compras de consumidores

hasta grandes órdenes corporativas. Esta diversidad es clave para diseñar estrategias de segmentación.

- **Rentabilidad dispersa:** La varianza de **Profit Margin** (en \$) es notable. Existen órdenes con alta rentabilidad junto a órdenes de ganancia casi nula, posiblemente producto de descuentos agresivos.
- **Descuentos activos:** Con un rango de descuentos del 0% al máximo observado, la empresa aplica una política de incentivos variable que merece monitoreo continuo en función de su impacto en el margen.
- **Dominio de Office Supplies:** El 79% de las órdenes pertenece a esta categoría, lo que indica que Furniture y Technology son categorías de oportunidad de crecimiento.

3. Detección de outliers

- Se detectaron outliers principalmente en variables monetarias de alto valor, consistentes con órdenes corporativas de gran volumen.
- Tras la eliminación, la desviación estándar se redujo significativamente en todas las variables, produciendo un dataset más representativo del **comportamiento típico** de las transacciones.
- **Recomendación de negocio:** Antes de eliminar outliers en producción, validar si corresponden a clientes estratégicos (B2B de alto valor) que no deben excluirse del análisis comercial.

4. Análisis de correlación

- Se esperan correlaciones muy fuertes entre variables derivadas (**Sub Total** , **Order Total** , **Total**), lo que confirma **redundancia estructural** en el dataset.
- La relación **Cost Price** ↔ **Retail Price** probablemente revela una política de markup fijo.
- La correlación **Discount %** ↔ **Profit Margin** es el hallazgo más estratégico: una correlación negativa fuerte confirmaría que los descuentos comprometen directamente la rentabilidad.

Limitaciones del dataset

Limitación	Impacto
Variables derivadas redundantes	Requieren reducción antes de modelar
Fechas no exploradas correlacionalmente	Análisis de tendencias temporales no realizado
Sin costos fijos operacionales	No es posible calcular rentabilidad neta real
Alta cardinalidad en City/State	Variables geográficas no analizadas cuantitativamente

Aplicaciones de negocio

Área	Aplicación potencial del análisis
Pricing y Revenue	Optimización de política de descuentos por categoría
Logística	Análisis de costo de envío por modalidad (Air vs. Truck)
Ventas	Segmentación de clientes por monto y frecuencia de compra
Finanzas	Identificación de productos con margen insuficiente
CRM	Priorización de clientes corporativos (Corporate: 36% de órdenes)

Consideraciones éticas

- El dataset contiene **datos personales** de clientes (nombre, dirección, ciudad), lo que implica obligaciones de privacidad bajo normativas como GDPR o la Ley N° 19.628 de Chile.
- Cualquier modelo predictivo construido sobre estos datos debe ser **transparente** respecto a las variables utilizadas para decisiones que afecten a clientes.
- La eliminación de outliers debe documentarse y justificarse: datos atípicos podrían corresponder a segmentos minoritarios cuya exclusión introduzca **sesgo en los modelos**.

Daniel Vargas · Analista de Datos · 12 de mayo de 2026